

Analisis Sentimen Ulasan Produk E-Commerce Menggunakan Metode TF-IDF dan Algoritma Support Vector Machine

Dengan tujuan memenuhi tugas besar mata kuliah Penggalan Data yang diampu oleh Ibu Vinna Rahmayanti S, S.Si., M.Si



Radhiya Astifa
202310370311281

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS MUHAMMADIYAH MALANG
2026**

ABSTRAK

Perkembangan e-commerce menyebabkan jumlah ulasan pelanggan pada platform digital meningkat secara signifikan. Ulasan tersebut mengandung opini yang dapat dimanfaatkan untuk memahami tingkat kepuasan pelanggan terhadap suatu produk. Namun, jumlah data ulasan yang besar menyebabkan proses analisis secara manual menjadi tidak efektif. Oleh karena itu, diperlukan pendekatan otomatis melalui analisis sentimen berbasis text mining dan machine learning. Penelitian ini bertujuan untuk melakukan klasifikasi sentimen terhadap ulasan produk e-commerce menggunakan metode Term Frequency–Inverse Document Frequency (TF-IDF) dan algoritma Support Vector Machine (SVM). Dataset yang digunakan adalah Women’s E-Commerce Clothing Reviews yang diperoleh dari Kaggle dan berisi ulasan pelanggan terhadap produk pakaian wanita. Tahapan penelitian meliputi data cleaning, Exploratory Data Analysis (EDA), feature selection, text preprocessing, serta representasi fitur menggunakan TF-IDF dengan pendekatan unigram dan bigram. Proses preprocessing mencakup lowercase transformation, penghapusan karakter non-alfabet, normalisasi spasi, serta stopword removal dengan mempertahankan kata negasi untuk menjaga konteks sentimen. Hasil representasi fitur akan digunakan pada tahap klasifikasi menggunakan algoritma SVM. Penelitian ini diharapkan mampu menghasilkan model klasifikasi sentimen yang efektif dalam mengidentifikasi opini pelanggan terhadap produk e-commerce.

Kata Kunci: Analisis Sentimen, E-Commerce, TF-IDF, Support Vector Machine, Text Mining

1. PENDAHULUAN

1.1. Latar Belakang

Perkembangan teknologi informasi dan internet telah mendorong pertumbuhan industri e-commerce secara pesat. Platform e-commerce tidak hanya digunakan sebagai media transaksi jual beli, tetapi juga menyediakan fitur ulasan pelanggan yang memungkinkan pengguna memberikan opini terhadap produk yang dibeli. Ulasan pelanggan menjadi salah satu sumber informasi penting karena sering dijadikan pertimbangan oleh calon pembeli sebelum melakukan transaksi.

Jumlah ulasan pelanggan yang terus meningkat menyebabkan proses analisis secara manual menjadi tidak efisien. Oleh karena itu, diperlukan pendekatan otomatis untuk memahami opini pelanggan melalui analisis sentimen. Analisis sentimen merupakan salah satu cabang text mining dan Natural Language Processing (NLP) yang digunakan untuk mengidentifikasi serta mengelompokkan opini ke dalam kategori tertentu, seperti positif dan negatif. Menurut Siregar dkk. (2024), analisis sentimen mampu membantu perusahaan memahami persepsi pengguna terhadap layanan atau produk berdasarkan data ulasan digital.

Dalam implementasinya, data teks ulasan sering mengandung noise, seperti karakter yang tidak relevan, penulisan yang tidak konsisten, penggunaan simbol, serta kata-kata umum yang tidak memiliki kontribusi signifikan terhadap klasifikasi. Oleh karena itu, proses preprocessing menjadi tahap penting sebelum dilakukan pemodelan machine learning. Ramadila dkk. (2025) menjelaskan bahwa preprocessing seperti case folding, stopword removal, dan cleaning berperan penting dalam meningkatkan kualitas data teks untuk klasifikasi sentimen.

Salah satu metode representasi fitur yang banyak digunakan dalam analisis sentimen adalah TF-IDF (Term Frequency–Inverse Document Frequency). Metode ini memberikan bobot terhadap kata berdasarkan tingkat kepentingannya dalam dokumen dan keseluruhan corpus. Harmandini dan Muslim (2024) menyatakan bahwa TF-IDF mampu menghasilkan representasi fitur yang efektif untuk proses klasifikasi teks pada data ulasan produk e-commerce.

Pada tahap klasifikasi, algoritma Support Vector Machine (SVM) dipilih karena memiliki performa yang baik dalam menangani data berdimensi tinggi, termasuk data teks hasil representasi TF-IDF. Penelitian oleh Siregar dkk. (2024) menunjukkan bahwa kombinasi NLP, TF-IDF, dan SVM mampu menghasilkan performa klasifikasi yang baik pada data ulasan e-commerce.

Penelitian ini menggunakan dataset Women's E-Commerce Clothing Reviews yang diperoleh dari Kaggle. Tahapan penelitian meliputi data cleaning, Exploratory Data Analysis (EDA), feature selection, text preprocessing, representasi fitur menggunakan TF-IDF, serta klasifikasi menggunakan algoritma SVM. Penelitian ini diharapkan dapat menghasilkan model klasifikasi sentimen yang mampu mengidentifikasi opini pelanggan secara efektif terhadap produk e-commerce.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah pada penelitian ini adalah:

1. Bagaimana proses analisis sentimen pada ulasan produk e-commerce menggunakan teknik text mining?
2. Bagaimana penerapan metode TF-IDF dalam representasi fitur teks ulasan pelanggan?
3. Bagaimana performa algoritma Support Vector Machine (SVM) dalam melakukan klasifikasi sentimen ulasan produk e-commerce?

1.3. Tujuan Penelitian

Tujuan dari penelitian ini adalah:

1. Melakukan analisis sentimen terhadap ulasan produk e-commerce.
2. Menerapkan metode TF-IDF untuk representasi fitur pada data teks.
3. Membangun model klasifikasi sentimen menggunakan algoritma Support Vector Machine (SVM).
4. Mengevaluasi performa model klasifikasi sentimen yang dihasilkan.

1.4. Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah:

1. Bagi Peneliti
Menambah pemahaman mengenai penerapan text mining, NLP, dan machine learning dalam analisis sentimen.
2. Bagi Akademik
Menjadi referensi penelitian terkait analisis sentimen menggunakan metode TF-IDF dan algoritma SVM.
3. Bagi Pelaku E-Commerce
Membantu memahami opini pelanggan terhadap produk berdasarkan hasil analisis ulasan secara otomatis.

2. METODOLOGI PENELITIAN

2.1. Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah Women's E-Commerce Clothing Reviews yang diperoleh dari platform Kaggle. Dataset tersebut berisi ulasan pelanggan terhadap produk pakaian wanita dan terdiri dari beberapa atribut, seperti usia pelanggan, rating produk, kategori produk, jumlah feedback positif, serta teks ulasan pelanggan.

Dataset awal terdiri dari 23.486 data dengan beberapa atribut utama, yaitu:

No	Nama Atribut	Keterangan
1	Clothing ID	ID produk
2	Age	Usia Pelanggan
3	Title	Judul ulasan
4	Review Text	Isi ulasan pelanggan
5	Rating	Rating produk
6	Recommended IND	Status rekomendasi produk
7	Positive Feedback Count	Jumlah feedback positif
8	Division Name	Divisi produk
9	Department Name	Departemen produk
10	Class Name	Kategori produk

Tabel 2.1 Nama Atribut beserta Keterangannya

Atribut Review Text digunakan sebagai fitur utama pada proses analisis sentimen, sedangkan atribut Recommended IND digunakan sebagai label klasifikasi sentimen.

2.2. Data Cleaning

Tahap data cleaning dilakukan untuk meningkatkan kualitas dataset sebelum masuk ke tahap analisis dan pemodelan. Proses ini penting karena data mentah umumnya masih mengandung missing value, duplikasi data, serta atribut yang tidak relevan.

Pada penelitian ini, proses data cleaning dilakukan melalui beberapa tahapan, yaitu:

1. Menghapus atribut yang tidak relevan, seperti kolom indeks otomatis.
2. Menangani missing value pada atribut Review Text dengan menghapus data yang tidak memiliki isi ulasan.
3. Mengisi missing value pada atribut kategorikal menggunakan nilai default.
4. Menghapus data duplikat untuk menghindari redundansi data.

2.3. Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik dataset sebelum proses pemodelan dilakukan. Tahap ini bertujuan untuk mengidentifikasi distribusi data, pola ulasan pelanggan, serta hubungan antar atribut.

Beberapa analisis yang dilakukan pada tahap EDA meliputi:

1. Distribusi rating produk.
2. Distribusi label label Recommended IND.
3. Distribusi kategori produk.
4. Analisis panjang teks ulasan.
5. Analisis hubungan panjang ulasan terhadap label sentimen.

Hasil EDA menunjukkan bahwa mayoritas pelanggan memberikan rating tinggi dan merekomendasikan produk yang dibeli. Selain itu,

2.4. Feature Selection

Feature selection dilakukan untuk memilih atribut yang paling relevan terhadap proses klasifikasi sentimen. Berdasarkan hasil EDA dan tujuan penelitian, atribut yang digunakan pada tahap pemodelan adalah:

Atribut	Fungsi
Review Text	Data teks utama
Recommended IND	Label sentimen

Tabel 2.2 Fungsi setiap Atribut

Atribut lainnya tetap digunakan pada tahap EDA untuk memahami karakteristik dataset, namun tidak digunakan secara langsung pada proses klasifikasi.

2.5. Text Preprocessing

Text preprocessing dilakukan untuk membersihkan dan menormalisasi data teks agar lebih terstruktur dan siap digunakan pada tahap representasi fitur. Menurut Ramadila dkk. (2025), preprocessing merupakan tahap penting dalam analisis sentimen karena dapat mengurangi noise pada data teks.

Tahapan preprocessing yang dilakukan pada penelitian ini meliputi:

1. Lowercase transformation.
2. Penghapusan karakter non-alfabet.
3. Normalisasi spasi.
4. Stopword removal.
5. Mempertahankan kata negasi seperti “not”, “no”, dan “never” untuk menjaga konteks sentiment.

Contoh hasil preprocessing dapat dilihat pada Tabel berikut:

Sebelum Preprocessing	Setelah Preprocessing
The dress is not good!!!	dress not good
I really love this product	really love product

Tabel 2.3 Perbandingan Review Sebelum dan Sesudah Preprocessing

Tahap preprocessing dilakukan menggunakan library re dan NLTK pada Python.

2.6. Represntasi Fitur Menggunakan TF-IDF

Setelah proses preprocessing selesai dilakukan, data teks direpresentasikan ke dalam bentuk numerik menggunakan metode TF-IDF (Term Frequency–Inverse Document Frequency). Metode ini digunakan untuk memberikan bobot terhadap kata berdasarkan tingkat kemunculannya pada dokumen dan corpus.

Pada penelitian ini, TF-IDF diterapkan menggunakan pendekatan unigram dan bigram dengan tujuan mempertahankan konteks dua kata yang memiliki makna sentimen tertentu, seperti “not good” atau “very bad”.

Parameter yang digunakan pada proses TF-IDF meliputi:

Parameter	Nilai
max features	5000
ngram range	(1,2)

Tabel 2.4 Parameter beserta Nilainya

Hasil representasi fitur TF-IDF akan digunakan sebagai input pada proses klasifikasi menggunakan algoritma SVM.

2.7. Train-Test Split

Data hasil representasi fitur menggunakan TF-IDF selanjutnya dibagi menjadi data training dan data testing menggunakan metode hold-out split. Pembagian data dilakukan dengan rasio 80:20, di mana 80% data digunakan sebagai data training dan 20% digunakan sebagai data testing.

Proses splitting dilakukan menggunakan fungsi `train_test_split` dari library Scikit-learn dengan parameter `stratify=y` untuk menjaga proporsi distribusi label sentimen pada data training dan testing tetap seimbang. Selain itu, parameter `random_state=42` digunakan untuk memastikan hasil pembagian data bersifat konsisten dan dapat direproduksi.

Data training digunakan untuk melatih model Support Vector Machine (SVM), sedangkan data testing digunakan untuk mengevaluasi performa model terhadap data yang belum pernah dilihat sebelumnya.

2.8. Training Model SVM

Tahap selanjutnya pada penelitian ini adalah proses pelatihan model klasifikasi menggunakan algoritma Support Vector Machine (SVM). Model yang digunakan adalah Linear Support Vector Classification (LinearSVC) dari library Scikit-learn. Pemilihan LinearSVC dilakukan karena data hasil representasi TF-IDF memiliki dimensi fitur yang tinggi dan berbentuk sparse matrix sehingga lebih sesuai ditangani menggunakan model linear.

Selain memiliki performa yang baik pada klasifikasi teks, LinearSVC juga lebih efisien dalam proses komputasi dibandingkan kernel non-linear. Pada tahap ini, model dilatih menggunakan data training hasil proses train-test split. Data training digunakan untuk mempelajari pola kata yang merepresentasikan sentimen positif dan negatif pada ulasan pelanggan. Proses training dilakukan menggunakan fungsi `fit()` pada Scikit-learn dengan parameter `random_state=42` untuk menjaga konsistensi hasil penelitian. Hasil training menunjukkan bahwa model berhasil mempelajari pola klasifikasi sentimen berdasarkan representasi fitur TF-IDF yang telah dibentuk sebelumnya.

2.9. Prediction

Setelah proses training selesai dilakukan, model SVM selanjutnya digunakan untuk melakukan prediksi terhadap data testing. Tahap prediction bertujuan untuk mengetahui kemampuan model dalam mengklasifikasikan data yang belum pernah dilihat sebelumnya. Proses prediksi dilakukan menggunakan fungsi `predict()` pada data testing hasil train-test split. Output dari proses ini berupa label sentimen hasil prediksi model yang terdiri dari kelas positif (1) dan negatif (0).

Hasil prediction menunjukkan bahwa sebagian besar review berhasil diklasifikasikan dengan benar oleh model. Review yang mengandung kata-kata positif seperti “love”, “great”, “comfortable”, dan “perfect” cenderung diprediksi sebagai sentimen positif. Sebaliknya,

review yang mengandung kata seperti “disappointed”, “poor”, atau “not flattering” cenderung diklasifikasikan sebagai sentimen negatif.

Namun, ditemukan beberapa kesalahan klasifikasi pada review yang memiliki konteks ambigu atau mengandung sentimen campuran. Hal ini menunjukkan bahwa model TF-IDF dan SVM masih memiliki keterbatasan dalam memahami konteks bahasa secara mendalam.

2.10. Evaluation Metrics

Tahap evaluasi dilakukan untuk mengukur performa model Support Vector Machine (SVM) dalam melakukan klasifikasi sentimen ulasan produk e-commerce. Evaluasi model dilakukan menggunakan beberapa metrik klasifikasi, yaitu accuracy, precision, recall, dan f1-score. Penggunaan beberapa metrik evaluasi diperlukan karena dataset penelitian memiliki distribusi label yang tidak seimbang, di mana jumlah data positif lebih dominan dibandingkan data negatif.

Berdasarkan hasil pengujian menggunakan data testing sebanyak 4.528 data, diperoleh nilai accuracy sebesar 88,52%. Hasil tersebut menunjukkan bahwa model mampu melakukan klasifikasi sentimen dengan tingkat ketepatan yang cukup tinggi terhadap data yang belum pernah dilihat sebelumnya. Nilai accuracy yang tinggi menunjukkan bahwa kombinasi preprocessing, TF-IDF, dan algoritma SVM mampu membangun model klasifikasi yang efektif pada dataset ulasan e-commerce.

Hasil evaluasi precision menunjukkan nilai sebesar 0,9188 atau sekitar 91,88%. Nilai tersebut menunjukkan bahwa sebagian besar prediksi sentimen positif yang dihasilkan model memang benar termasuk ke dalam kelas positif. Tingginya precision mengindikasikan bahwa model relatif baik dalam meminimalkan kesalahan prediksi positif palsu (*false positive*).

Sementara itu, nilai recall sebesar 0,9431 atau sekitar 94,31% menunjukkan bahwa model mampu mengenali sebagian besar data sentimen positif yang terdapat pada dataset testing. Nilai recall yang lebih tinggi dibandingkan precision menunjukkan bahwa model cenderung lebih fokus dalam mendeteksi kelas positif dibandingkan membatasi kesalahan prediksi positif.

Nilai f1-score yang diperoleh sebesar 0,9308 menunjukkan bahwa model memiliki keseimbangan yang baik antara precision dan recall. Menurut Barus dkk. (2024), f1-score menjadi salah satu metrik penting dalam klasifikasi sentimen karena mampu menggambarkan performa model secara lebih seimbang, khususnya pada dataset yang memiliki distribusi kelas tidak merata.

Hasil classification report juga menunjukkan adanya perbedaan performa antara kelas positif dan negatif. Pada kelas negatif (label 0), model memperoleh precision sebesar 0,71, recall sebesar 0,62, dan f1-score sebesar 0,66. Sedangkan pada kelas positif (label 1), model memperoleh precision sebesar 0,92, recall sebesar **0,94**, dan f1-score sebesar **0,93**. Perbedaan tersebut menunjukkan bahwa model lebih optimal dalam mengenali ulasan positif dibandingkan ulasan negatif.

Hal tersebut dipengaruhi oleh distribusi dataset yang tidak seimbang (*imbalanced dataset*), di mana jumlah data positif jauh lebih banyak dibandingkan data negatif. Pada dataset penelitian ini, jumlah label positif mencapai 18.539 data, sedangkan label negatif hanya sebanyak 4.101 data. Kondisi tersebut menyebabkan model lebih sering mempelajari pola dari kelas mayoritas sehingga performa pada kelas minoritas menjadi lebih rendah.


Meskipun demikian, hasil evaluasi secara keseluruhan menunjukkan bahwa baseline model SVM yang dibangun sudah mampu menghasilkan performa klasifikasi yang baik untuk tahap awal penelitian. Kombinasi preprocessing teks, representasi fitur TF-IDF unigram dan bigram, serta algoritma SVM terbukti cukup efektif dalam melakukan analisis sentimen pada ulasan produk e-commerce.

2.11. Confusion Matrix

Confusion matrix digunakan untuk melihat performa klasifikasi model secara lebih detail berdasarkan jumlah prediksi benar dan prediksi salah pada masing-masing kelas. Melalui

confusion matrix, dapat diketahui bagaimana model mengklasifikasikan data positif maupun negatif.

Berdasarkan hasil pengujian, diperoleh confusion matrix sebagai berikut:



Gambar 2.1 Confusion Matrix

Berdasarkan confusion matrix tersebut, diketahui bahwa model berhasil memprediksi 511 data negatif dengan benar (*true negative*) dan 3497 data positif dengan benar (*true positive*). Selain itu, terdapat 309 data negatif yang diprediksi sebagai positif (*false positive*) dan 211 data positif yang diprediksi sebagai negatif (*false negative*).

Jumlah true positive yang sangat tinggi menunjukkan bahwa model sangat baik dalam mengenali ulasan yang termasuk ke dalam kategori recommended. Hal ini selaras dengan nilai recall kelas positif yang mencapai 94%. Namun, jumlah false positive yang masih cukup besar menunjukkan bahwa model terkadang menganggap ulasan negatif sebagai ulasan positif.

Kesalahan prediksi tersebut dapat disebabkan oleh beberapa faktor, seperti penggunaan kata-kata positif pada ulasan negatif, adanya konteks kalimat yang ambigu, serta keterbatasan representasi fitur TF-IDF dalam memahami makna semantik secara mendalam. Sebagai contoh, ulasan seperti “*the material is good but the size is disappointing*” masih mengandung kata positif seperti *good*, sehingga model dapat mengalami kesalahan klasifikasi.

Selain itu, distribusi label yang tidak seimbang juga mempengaruhi hasil confusion matrix. Karena model lebih banyak mempelajari pola dari kelas positif, model menjadi lebih sensitif terhadap ciri-ciri ulasan positif dibandingkan ulasan negatif. Menurut Ramadila dkk. (2025), kondisi dataset imbalance dapat menyebabkan model klasifikasi memiliki bias terhadap kelas mayoritas sehingga performa pada kelas minoritas cenderung menurun.

Secara keseluruhan, confusion matrix menunjukkan bahwa model baseline SVM sudah memiliki performa yang cukup baik dalam melakukan klasifikasi sentimen ulasan e-commerce. Meskipun masih terdapat beberapa kesalahan prediksi, model telah mampu mengenali pola sentimen positif dan negatif dengan tingkat akurasi yang tinggi.

2.12. Analisis Hasil Model

Berdasarkan hasil pengujian yang telah dilakukan, model Support Vector Machine (SVM) berhasil mencapai accuracy sebesar 88,52% dengan f1-score sebesar 93,08% pada kelas positif. Hasil tersebut menunjukkan bahwa model memiliki kemampuan klasifikasi yang cukup baik terhadap data ulasan produk e-commerce.

Performa model yang baik dipengaruhi oleh tahap preprocessing yang dilakukan sebelum proses pelatihan model. Proses lowercase transformation, penghapusan karakter non-alfabet, normalisasi spasi, serta stopwords removal membantu mengurangi noise pada data teks sehingga fitur yang dihasilkan menjadi lebih relevan untuk proses klasifikasi. Selain itu,

mempertahankan kata negasi seperti *not*, *no*, dan *never* membantu model memahami konteks sentimen negatif yang sering muncul pada ulasan pelanggan.

Penggunaan TF-IDF dengan pendekatan unigram dan bigram juga memberikan kontribusi penting terhadap performa model. Representasi unigram memungkinkan model mengenali kata individual yang memiliki makna sentimen, sedangkan bigram membantu mempertahankan konteks dua kata seperti *not good*, *very disappointed*, atau *high quality*. Menurut Harmandini dan Muslim (2024), penggunaan TF-IDF dengan kombinasi unigram dan bigram mampu meningkatkan kualitas representasi fitur pada klasifikasi ulasan produk.

Meskipun hasil evaluasi menunjukkan performa yang cukup tinggi, model masih menunjukkan kecenderungan bias terhadap kelas mayoritas. Hal tersebut terlihat dari perbedaan performa antara kelas positif dan negatif. Kelas positif memperoleh f1-score sebesar 0,93, sedangkan kelas negatif hanya memperoleh f1-score sebesar 0,66. Perbedaan tersebut menunjukkan bahwa model lebih mudah mengenali pola ulasan positif dibandingkan ulasan negatif.

Kondisi tersebut dipengaruhi oleh distribusi dataset yang tidak seimbang. Jumlah ulasan positif yang jauh lebih banyak menyebabkan model lebih sering mempelajari karakteristik kelas positif selama proses training. Akibatnya, model cenderung mengklasifikasikan ulasan ambigu ke dalam kelas positif.

Perbedaan nilai precision dan recall juga menunjukkan karakteristik model dalam melakukan klasifikasi. Nilai recall yang lebih tinggi dibandingkan precision menunjukkan bahwa model cukup agresif dalam mendeteksi ulasan positif. Hal ini menyebabkan jumlah false negative menjadi lebih kecil, namun masih menghasilkan beberapa false positive.


Secara keseluruhan, baseline model SVM yang dibangun pada penelitian ini sudah mampu menghasilkan performa klasifikasi yang baik untuk tahap awal penelitian. Hasil tersebut menunjukkan bahwa kombinasi preprocessing teks, TF-IDF, dan SVM cukup efektif dalam melakukan analisis sentimen pada ulasan produk e-commerce. Namun demikian, masih terdapat peluang pengembangan model lebih lanjut, seperti penanganan imbalance dataset, hyperparameter tuning, maupun penggunaan metode representasi fitur berbasis word embedding untuk meningkatkan performa klasifikasi pada kelas negatif.

2.13. Cross Validation

Tahap cross validation dilakukan untuk mengukur stabilitas performa model Support Vector Machine (SVM) pada beberapa pembagian data yang berbeda. Penggunaan cross validation penting untuk memastikan bahwa model tidak hanya memiliki performa yang baik pada satu kali pembagian data, tetapi juga mampu melakukan generalisasi terhadap data baru.

Pada penelitian ini digunakan metode K-Fold Cross Validation dengan nilai $k = 5$. Dataset training dibagi menjadi lima bagian (*fold*), kemudian proses training dan testing dilakukan secara bergantian hingga seluruh fold pernah digunakan sebagai data pengujian.

Metode cross validation dipilih karena mampu menghasilkan evaluasi model yang lebih stabil dan reliabel dibandingkan hanya menggunakan satu kali train-test split. Menurut Barus dkk. (2024), cross validation dapat membantu mengurangi risiko bias evaluasi model serta meningkatkan validitas performa klasifikasi pada data ulasan e-commerce.



Gambar 2.2 Grafik Cross Validation

Berdasarkan hasil cross validation menggunakan 5-fold, model memperoleh rata-rata accuracy sebesar sekitar 0,89 dengan standar deviasi yang relatif kecil. Nilai tersebut menunjukkan bahwa performa model cenderung stabil pada setiap fold pengujian. Stabilitas hasil cross validation menunjukkan bahwa model tidak hanya bekerja baik pada satu pembagian data tertentu, tetapi juga mampu mempertahankan performa klasifikasi pada beberapa variasi data training dan testing.

Nilai standar deviasi yang kecil menunjukkan bahwa perbedaan accuracy antar fold tidak terlalu jauh. Hal tersebut mengindikasikan bahwa model memiliki kemampuan generalisasi yang cukup baik dan tidak mengalami fluktuasi performa yang ekstrem. Hasil cross validation ini memperkuat hasil evaluasi sebelumnya yang menunjukkan bahwa algoritma SVM cukup efektif digunakan untuk klasifikasi sentimen berbasis TF-IDF pada data ulasan e-commerce.

2.14. Hyperparameter Tuning


Hyperparameter tuning dilakukan untuk meningkatkan performa model Support Vector Machine (SVM) melalui pencarian kombinasi parameter terbaik. Pada penelitian ini, tuning dilakukan menggunakan metode Grid Search Cross Validation dengan bantuan library Scikit-learn. Parameter yang diuji meliputi nilai parameter C, jenis loss function, dan jumlah iterasi maksimum model.

Proses tuning dilakukan menggunakan 5-Fold Cross Validation dengan metrik evaluasi weighted F1-score. Penggunaan weighted F1-score dipilih karena distribusi label pada dataset tidak seimbang, di mana jumlah data sentimen positif lebih banyak dibandingkan sentimen negatif. Menurut Barus dkk. (2024), pemilihan parameter yang tepat dapat membantu meningkatkan kemampuan generalisasi model pada proses klasifikasi sentiment

index	params	mean test score	rank test score
14	{'C': 1, 'loss': 'hinge', 'max_iter': 5000}	0.891172	1
12	{'C': 1, 'loss': 'hinge', 'max_iter': 1000}	0.891172	1
13	{'C': 1, 'loss': 'hinge', 'max_iter': 3000}	0.891172	1
15	{'C': 1, 'loss': 'squared hinge', 'max_iter': ...}	0.887759	4
17	{'C': 1, 'loss': 'squared hinge', 'max_iter': ...}	0.887759	4

Tabel 2.5 Hasil Kombinasi Hyperparameter Menggunakan Grid Cross Validation

Berdasarkan hasil Grid Search, kombinasi parameter terbaik diperoleh pada model dengan nilai C = 1, loss = hinge, dan max_iter = 5000. Kombinasi parameter tersebut menghasilkan nilai mean test score tertinggi dibandingkan kombinasi parameter lainnya. Hasil ini menunjukkan bahwa model SVM linear cukup optimal digunakan pada data TF-IDF yang memiliki dimensi tinggi dan sparse matrix.



Gambar 2.3 Perbandingan Akurasi Baseline SVM dan Tuned SVM


Setelah menggunakan parameter terbaik, performa model mengalami peningkatan dibandingkan baseline model sebelumnya. Nilai accuracy meningkat dari 0,885159 menjadi 0,893330 setelah dilakukan hyperparameter tuning. Selain itu, model menghasilkan precision sebesar 0,92, recall sebesar 0,96, dan F1-score sebesar 0,94 pada kelas sentimen positif.

Meskipun performa model meningkat, hasil evaluasi menunjukkan bahwa model masih lebih baik dalam mengklasifikasikan sentimen positif dibandingkan sentimen negatif. Hal ini terlihat dari nilai recall kelas negatif yang masih berada pada angka 0,61. Kondisi tersebut dipengaruhi oleh distribusi dataset yang tidak seimbang sehingga model cenderung lebih fokus mempelajari pola pada kelas mayoritas. Namun secara keseluruhan, kombinasi preprocessing, TF-IDF unigram-bigram, dan SVM linear mampu menghasilkan performa klasifikasi yang cukup baik pada data ulasan e-commerce.

2.15. Handling Imbalanced Dataset

Ketidakseimbangan distribusi label merupakan salah satu permasalahan yang sering ditemukan pada proses klasifikasi sentimen. Pada dataset penelitian ini, jumlah data sentimen positif lebih banyak dibandingkan sentimen negatif sehingga berpotensi menyebabkan model lebih cenderung memprediksi kelas mayoritas. Kondisi tersebut dapat mempengaruhi kemampuan model dalam mengenali data pada kelas minoritas.

Untuk mengatasi permasalahan tersebut, penelitian ini menerapkan metode SMOTE (Synthetic Minority Oversampling Technique). Metode SMOTE bekerja dengan menghasilkan data sintesis pada kelas minoritas sehingga distribusi data training menjadi lebih seimbang. Menurut Barus dkk. (2024), penggunaan SMOTE dapat membantu meningkatkan performa model klasifikasi pada dataset yang tidak seimbang.




Gambar 2.4 Distribusi Label Sebelum dan Sesudah SMOTE

Berdasarkan hasil visualisasi distribusi label, terlihat bahwa jumlah data sentimen negatif meningkat setelah proses oversampling dilakukan. Sebelum penerapan SMOTE, distribusi data training didominasi oleh kelas sentimen positif. Setelah SMOTE diterapkan,

jumlah data pada kedua kelas menjadi seimbang sehingga model memiliki kesempatan yang lebih baik untuk mempelajari pola pada masing-masing kelas.

Setelah proses balancing dilakukan, model SVM dilatih kembali menggunakan data hasil SMOTE. Hasil evaluasi kemudian dibandingkan dengan baseline model dan model hasil hyperparameter tuning sebelumnya untuk melihat pengaruh penanganan imbalance terhadap performa klasifikasi.



Gambar 2.5 Perbandingan Accuracy Baseline, SVM, Tuned SVM, dan SVM + SMOTE

Hasil evaluasi menunjukkan bahwa penerapan SMOTE memberikan pengaruh terhadap performa model, terutama pada kemampuan model dalam mengenali kelas minoritas. Dengan distribusi data yang lebih seimbang, model diharapkan mampu mengurangi bias terhadap kelas mayoritas dan menghasilkan klasifikasi sentimen yang lebih stabil.


2.16. Dimensionality Reduction

Dimensionality reduction dilakukan untuk mengurangi jumlah fitur hasil representasi TF-IDF yang memiliki dimensi tinggi. Pada penelitian ini digunakan metode Truncated Singular Value Decomposition (Truncated SVD) karena metode tersebut lebih sesuai untuk data sparse matrix seperti hasil ekstraksi fitur TF-IDF. Menurut Aggarwal dan Zhai (2021), reduksi dimensi pada data teks dapat membantu mengurangi kompleksitas model serta meningkatkan efisiensi komputasi tanpa harus menghilangkan keseluruhan informasi penting pada data.

Pada penelitian ini, jumlah fitur TF-IDF sebanyak 5000 fitur direduksi menjadi 300 komponen utama menggunakan Truncated SVD. Proses reduksi dimensi dilakukan setelah tahap handling imbalanced dataset menggunakan SMOTE dan sebelum proses klasifikasi menggunakan algoritma Support Vector Machine (SVM). Selain membantu mengurangi kompleksitas data, reduksi dimensi juga bertujuan untuk mengurangi noise dan redundansi fitur yang dapat mempengaruhi performa model klasifikasi.

Berdasarkan hasil reduksi dimensi, nilai total explained variance yang diperoleh sebesar 0,3930 atau sekitar 39,3%. Hasil tersebut menunjukkan bahwa sebagian informasi penting dari fitur TF-IDF masih dapat direpresentasikan ke dalam dimensi yang lebih rendah. Pada data teks berbasis TF-IDF, nilai explained variance cenderung lebih rendah dibandingkan data numerik biasa karena distribusi informasi tersebar pada banyak fitur kata. Oleh karena itu, nilai explained variance sebesar 39,3% masih tergolong wajar pada proses text mining dengan jumlah fitur yang tinggi.

Setelah dilakukan dimensionality reduction, model SVM kembali dilatih menggunakan data hasil reduksi dimensi. Hasil evaluasi menunjukkan bahwa model masih mampu mempertahankan performa klasifikasi dengan baik meskipun jumlah fitur telah dikurangi secara signifikan. Hal tersebut menunjukkan bahwa Truncated SVD mampu mempertahankan fitur-fitur penting yang relevan terhadap proses klasifikasi sentimen.



Gambar 2.6 Perbandingan Accuracy Model Sebelum dan Sesudah Dimsionalitas Reduction

Gambar tersebut menunjukkan perbandingan accuracy model pada beberapa tahapan penelitian, mulai dari baseline SVM, hyperparameter tuning, handling imbalance dataset menggunakan SMOTE, hingga setelah penerapan dimensionality reduction. Berdasarkan hasil tersebut, reduksi dimensi mampu membantu proses klasifikasi menjadi lebih efisien dengan penurunan performa yang relatif kecil serta kompleksitas model yang lebih rendah.

3. HASIL DAN PEMBAHASAN

3.1. Hasil Klasifikasi Sentimen Menggunakan SVM

Pada penelitian ini, proses klasifikasi sentimen dilakukan menggunakan algoritma Support Vector Machine (SVM) dengan representasi fitur TF-IDF unigram dan bigram. Model dilatih menggunakan data hasil preprocessing yang telah dibersihkan melalui proses lowercase transformation, penghapusan karakter non-alfabet, normalisasi spasi, serta stopwords removal dengan tetap mempertahankan kata negasi. Tahapan tersebut dilakukan untuk menghasilkan representasi teks yang lebih terstruktur sehingga dapat meningkatkan kualitas proses klasifikasi sentimen.

Berdasarkan hasil pengujian terhadap data testing, model baseline SVM menghasilkan nilai accuracy sebesar 0,8852 atau sekitar 88,52%. Selain itu, model memperoleh nilai precision sebesar 0,9188, recall sebesar 0,9431, dan F1-score sebesar 0,9308 pada kelas sentimen positif. Hasil tersebut menunjukkan bahwa model mampu mengidentifikasi sebagian besar ulasan positif dengan cukup baik. Tingginya nilai recall pada kelas positif mengindikasikan bahwa model berhasil mengenali mayoritas data recommended review pada dataset.

Meskipun demikian, performa model pada kelas sentimen negatif masih lebih rendah dibandingkan kelas positif. Berdasarkan classification report, kelas negatif memperoleh nilai precision sebesar 0,71 dan recall sebesar 0,62. Hal tersebut menunjukkan bahwa model masih mengalami kesalahan dalam mengenali beberapa ulasan negatif dan cenderung memprediksi sebagian data negatif sebagai sentimen positif. Kondisi tersebut dipengaruhi oleh distribusi dataset yang tidak seimbang, di mana jumlah data positif jauh lebih banyak dibandingkan data negatif.

Secara umum, hasil klasifikasi menunjukkan bahwa kombinasi preprocessing, TF-IDF unigram-bigram, dan algoritma SVM mampu menghasilkan performa yang cukup baik dalam melakukan analisis sentimen pada ulasan produk e-commerce. Hasil ini juga sejalan dengan penelitian Ramadila dkk. (2025) yang menyatakan bahwa kombinasi TF-IDF dan SVM efektif digunakan untuk klasifikasi sentimen pada data ulasan e-commerce karena mampu menangani data teks berdimensi tinggi dengan baik.

3.2. Analisis Performas Model

Evaluasi performa model dilakukan menggunakan beberapa metrik klasifikasi, yaitu accuracy, precision, recall, F1-score, serta confusion matrix. Penggunaan beberapa metrik evaluasi diperlukan karena accuracy saja belum cukup untuk menggambarkan performa model pada dataset yang memiliki distribusi kelas tidak seimbang. Pada penelitian ini, jumlah data sentimen positif lebih mendominasi dibandingkan data sentimen negatif sehingga diperlukan analisis evaluasi yang lebih mendalam.

Berdasarkan hasil confusion matrix, model berhasil mengklasifikasikan 3497 data positif dengan benar dan 511 data negatif dengan benar. Namun, masih terdapat 309 data negatif yang diprediksi sebagai positif serta 211 data positif yang diprediksi sebagai negatif. Hasil tersebut menunjukkan bahwa model cenderung lebih baik dalam mengenali kelas mayoritas dibandingkan kelas minoritas. Tingginya jumlah prediksi benar pada kelas positif menyebabkan nilai recall kelas positif mencapai 0,94.

Setelah dilakukan hyperparameter tuning menggunakan Grid Search Cross Validation, performa model mengalami peningkatan dibandingkan baseline model sebelumnya. Accuracy meningkat dari 0,885159 menjadi 0,893330. Selain itu, nilai precision dan recall pada kelas positif juga mengalami peningkatan. Peningkatan performa tersebut menunjukkan bahwa pemilihan kombinasi parameter yang tepat dapat membantu model menghasilkan generalisasi yang lebih baik terhadap data testing.

Penelitian ini juga menerapkan handling imbalanced dataset menggunakan metode SMOTE untuk mengurangi bias model terhadap kelas mayoritas. Setelah dilakukan oversampling pada data training, model menjadi lebih mampu mengenali data sentimen negatif dibandingkan sebelumnya. Selain itu, penerapan dimensionality reduction menggunakan Truncated SVD membantu mengurangi kompleksitas fitur TF-IDF yang memiliki dimensi tinggi tanpa menurunkan performa model secara signifikan. Secara keseluruhan, tahapan preprocessing, tuning parameter, handling imbalance dataset, dan reduksi dimensi memberikan kontribusi terhadap peningkatan kualitas model klasifikasi sentimen yang dihasilkan.

3.3. Analisis Pengaruh Preprocessing dan TF-IDF

Tahap preprocessing memberikan pengaruh penting terhadap kualitas representasi data teks sebelum dilakukan proses klasifikasi. Pada penelitian ini, preprocessing dilakukan melalui beberapa tahapan, yaitu lowercase transformation, penghapusan karakter non-alfabet, normalisasi spasi, serta stopwords removal. Proses tersebut membantu mengurangi noise pada data teks sehingga model dapat lebih fokus pada kata-kata yang memiliki makna sentimen.

Selain itu, penelitian ini mempertahankan kata negasi seperti “not”, “no”, dan “never” selama proses preprocessing. Keputusan tersebut dilakukan karena kata negasi memiliki pengaruh besar terhadap konteks sentimen suatu kalimat. Sebagai contoh, frasa “not good” memiliki makna sentimen yang berbeda dibandingkan kata “good”. Oleh karena itu, mempertahankan kata negasi membantu model memahami konteks opini pelanggan dengan lebih baik.

Representasi fitur menggunakan TF-IDF unigram dan bigram juga memberikan kontribusi terhadap performa model klasifikasi. Penggunaan unigram memungkinkan model mengenali kata-kata penting secara individual, sedangkan bigram membantu mempertahankan konteks dua kata yang sering digunakan dalam opini pelanggan, seperti “very comfortable”, “high quality”, atau “not worth”. Menurut Harmandini dan Muslim (2024), penggunaan kombinasi unigram dan bigram mampu meningkatkan kualitas representasi fitur pada analisis sentimen karena model dapat memahami hubungan antar kata secara lebih kontekstual.

Hasil penelitian menunjukkan bahwa kombinasi preprocessing dan TF-IDF unigram-bigram mampu menghasilkan representasi fitur yang cukup baik untuk proses klasifikasi menggunakan algoritma SVM. Hal tersebut terlihat dari performa model yang mampu mencapai accuracy di atas 88% pada baseline model dan mengalami peningkatan setelah dilakukan optimasi model. Dengan demikian, preprocessing dan representasi fitur menjadi

tahapan yang sangat berpengaruh terhadap keberhasilan proses analisis sentimen pada penelitian ini.


3.4. Analisis Feature Importance

Analisis feature importance dilakukan untuk mengetahui kata-kata yang paling berpengaruh terhadap hasil klasifikasi sentimen pada model Support Vector Machine (SVM). Pada penelitian ini, feature importance diperoleh dari nilai koefisien model LinearSVC terhadap fitur hasil representasi TF-IDF unigram dan bigram. Nilai koefisien positif menunjukkan kata yang cenderung berkaitan dengan sentimen positif, sedangkan nilai koefisien negatif menunjukkan kata yang lebih sering muncul pada sentimen negatif.

	feature	coefficient
2406	love	3.037522
3077	perfect	2.820413
2271	little	2.582257
4525	unique	2.414871
4119	stunning	2.393904

Table 3.1 Kata dengan Bobot Positif Tertinggi pada Model SVM

Berdasarkan hasil analisis, beberapa kata yang memiliki bobot positif tertinggi antara lain “love”, “perfect”, “comfortable”, “great”, dan “flattering”. Kata-kata tersebut menunjukkan bahwa pelanggan cenderung memberikan ulasan positif terhadap produk yang dianggap nyaman digunakan, sesuai ukuran, dan memiliki kualitas yang baik. Selain itu, munculnya beberapa bigram seperti “high quality” atau “fits perfectly” menunjukkan bahwa penggunaan TF-IDF unigram dan bigram membantu model memahami konteks opini pelanggan secara lebih spesifik.




Gambar 3.1 Kata Dominan pada Sentimen Positif

	feature	coefficient
4626	wanted love	-4.650430
959	disappointrd	-4.104909
2808	not flattering	-3.426358
3468	returning	-3.041770
1651	going back	-3.041770

Table 3.2 Kata dengan bobot Negatif tertinggi pada Model SVM

Sementara itu, kata-kata dengan bobot negatif tertinggi antara lain “rwanted love”, “disappointed”, “returning”, “not flattering”, dan “uncomfortable”. Kata-kata tersebut menunjukkan bahwa sebagian besar ulasan negatif berkaitan dengan ketidaksesuaian ukuran, kualitas produk yang tidak sesuai ekspektasi, atau ketidaknyamanan saat digunakan. Hasil tersebut juga menunjukkan bahwa model mampu mengenali pola kata yang memiliki hubungan kuat terhadap sentimen pelanggan.



Gambar 3.2 Kata Dominan pada Sentimen Negatif

Visualisasi feature importance pada Gambar 3.1 dan Gambar 3.2 memperlihatkan distribusi kata dominan pada masing-masing kelas sentimen. Menurut Barus dkk. (2024), analisis kata dominan dapat membantu memberikan interpretasi terhadap hasil klasifikasi sentimen serta membantu memahami faktor utama yang mempengaruhi opini pelanggan pada platform e-commerce. Dengan demikian, hasil feature importance tidak hanya membantu interpretasi model machine learning, tetapi juga memberikan insight yang dapat dimanfaatkan untuk evaluasi kualitas produk dan pengalaman pelanggan.


3.5. Perbandingan Performa Model

Penelitian ini melakukan beberapa tahapan pengembangan model untuk meningkatkan kualitas klasifikasi sentimen, mulai dari baseline SVM, hyperparameter tuning, handling imbalanced dataset menggunakan SMOTE, hingga dimensionality reduction menggunakan Truncated SVD. Setiap tahapan dilakukan secara bertahap untuk melihat pengaruh preprocessing dan optimasi model terhadap performa klasifikasi sentimen pada ulasan produk e-commerce.

	model	Accuracy	Precision	Recall	F1-score
0	Baseline SVM	0.8852	0.9188	0.9431	0.9308
1	Tuned SVM	0.8933	0.9200	0.9600	0.9400
2	Tuned SVM + SMOTE	0.8900	0.8900	0.8900	0.8900
3	Tuned SVM + SMOTE + SVD	0.8900	0.8900	0.8900	0.8900

Table 3.3 Ringkasan Performa Model pada Setiap tahap Pengujian

Berdasarkan hasil pengujian, baseline model SVM menghasilkan accuracy sebesar 0,885159. Setelah dilakukan hyperparameter tuning menggunakan Grid Search Cross Validation, performa model meningkat menjadi 0,893330. Peningkatan tersebut menunjukkan bahwa pemilihan kombinasi parameter yang tepat mampu membantu model menghasilkan generalisasi yang lebih baik terhadap data testing. Selain meningkatkan accuracy, tuning parameter juga membantu meningkatkan precision dan recall pada kelas sentimen positif.



Gambar 3.4 Perbandingan Accuracy pada Setiap tahap Pengembangan Model

Tahap handling imbalanced dataset menggunakan metode SMOTE dilakukan karena distribusi label pada dataset tidak seimbang, di mana jumlah data sentimen positif jauh lebih banyak dibandingkan data sentimen negatif. Setelah dilakukan oversampling pada data training, model menjadi lebih mampu mengenali pola pada kelas minoritas sehingga performa klasifikasi sentimen negatif mengalami peningkatan. Meskipun demikian, model masih menunjukkan kecenderungan lebih baik dalam mengklasifikasikan kelas mayoritas dibandingkan kelas minoritas.

Selain itu, penelitian ini juga menerapkan dimensionality reduction menggunakan Truncated SVD untuk mengurangi kompleksitas fitur TF-IDF yang memiliki dimensi tinggi. Hasil pengujian menunjukkan bahwa model tetap mampu mempertahankan performa klasifikasi dengan baik meskipun jumlah fitur direduksi secara signifikan. Hal tersebut menunjukkan bahwa sebagian besar informasi penting pada fitur TF-IDF masih berhasil dipertahankan setelah proses reduksi dimensi dilakukan.

Secara keseluruhan, kombinasi preprocessing, TF-IDF unigram-bigram, hyperparameter tuning, handling imbalance dataset, dan dimensionality reduction memberikan kontribusi terhadap peningkatan kualitas model klasifikasi sentimen. Hasil tersebut menunjukkan bahwa pendekatan text mining dan machine learning yang digunakan pada penelitian ini mampu menghasilkan model klasifikasi sentimen yang cukup baik untuk data ulasan e-commerce.

3.6. Pembahasan Keseluruhan Penelitian

Berdasarkan keseluruhan tahapan penelitian yang telah dilakukan, proses analisis sentimen pada ulasan produk e-commerce berhasil diterapkan menggunakan pendekatan text mining dan machine learning. Tahapan preprocessing memberikan pengaruh penting terhadap kualitas data teks karena membantu mengurangi noise serta menghasilkan representasi teks yang lebih terstruktur sebelum dilakukan proses klasifikasi. Selain itu, mempertahankan kata negasi seperti “not”, “no”, dan “never” membantu model memahami konteks sentimen secara lebih baik.

Representasi fitur menggunakan TF-IDF unigram dan bigram juga memberikan kontribusi terhadap performa model klasifikasi. Penggunaan unigram membantu model mengenali kata-kata penting secara individual, sedangkan bigram membantu mempertahankan konteks dua kata yang memiliki makna sentimen tertentu. Hasil feature importance menunjukkan bahwa model mampu mengenali kata-kata dominan yang berkaitan dengan opini pelanggan, seperti “love”, “comfortable”, dan “perfect” pada sentimen positif serta “disappointed”, “returned”, dan “not fit” pada sentimen negatif.

Algoritma Support Vector Machine (SVM) menunjukkan performa yang cukup baik dalam melakukan klasifikasi sentimen pada dataset Women’s E-Commerce Clothing Reviews. Hal tersebut terlihat dari nilai accuracy yang mencapai lebih dari 88% pada baseline model dan mengalami peningkatan setelah dilakukan hyperparameter tuning. Menurut Siregar dkk.

(2024), SVM memiliki kemampuan yang baik dalam menangani data teks berdimensi tinggi sehingga banyak digunakan pada penelitian klasifikasi sentimen berbasis TF-IDF.

Meskipun performa model sudah tergolong baik, penelitian ini masih menemukan beberapa keterbatasan, terutama pada distribusi dataset yang tidak seimbang. Jumlah data sentimen positif yang lebih dominan menyebabkan model cenderung lebih baik dalam mengenali kelas mayoritas dibandingkan kelas minoritas. Oleh karena itu, penelitian ini menerapkan metode SMOTE untuk membantu meningkatkan kemampuan model dalam mengenali sentimen negatif.

Selain itu, penerapan dimensionality reduction menggunakan Truncated SVD membantu mengurangi kompleksitas fitur TF-IDF yang memiliki dimensi tinggi tanpa menurunkan performa model secara signifikan. Dengan demikian, penelitian ini menunjukkan bahwa kombinasi preprocessing, TF-IDF, dan SVM merupakan pendekatan yang cukup efektif untuk melakukan analisis sentimen pada data ulasan produk e-commerce.

Secara umum, hasil penelitian menunjukkan bahwa proses text mining dapat dimanfaatkan untuk membantu memahami opini pelanggan secara otomatis berdasarkan data ulasan digital. Informasi tersebut dapat menjadi bahan evaluasi bagi pelaku e-commerce dalam meningkatkan kualitas produk maupun layanan berdasarkan sentimen pelanggan yang diperoleh dari hasil analisis ulasan.

4. PENUTUP

4.1. Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, metode TF-IDF dan algoritma Support Vector Machine (SVM) mampu diterapkan dengan baik pada proses analisis sentimen ulasan produk e-commerce menggunakan dataset *Women's E-Commerce Clothing Reviews*. Tahapan penelitian dimulai dari data cleaning, exploratory data analysis (EDA), preprocessing teks, representasi fitur menggunakan TF-IDF unigram dan bigram, hingga proses klasifikasi menggunakan model SVM.

Hasil preprocessing terbukti membantu meningkatkan kualitas data teks dengan mengurangi noise pada ulasan pelanggan. Selain itu, penggunaan TF-IDF unigram dan bigram mampu mempertahankan konteks kata yang berhubungan dengan sentimen, seperti frasa “not good” atau “very comfortable”, sehingga representasi fitur menjadi lebih informatif untuk proses klasifikasi.

Model baseline SVM menghasilkan accuracy sebesar 0,8852 dengan nilai F1-score sebesar 0,9308 pada kelas sentimen positif. Setelah dilakukan hyperparameter tuning menggunakan Grid Search Cross Validation, performa model meningkat menjadi 0,8933. Hasil tersebut menunjukkan bahwa pemilihan parameter yang tepat dapat membantu meningkatkan kemampuan model dalam melakukan klasifikasi sentimen.

Penelitian ini juga menunjukkan bahwa distribusi label yang tidak seimbang mempengaruhi performa model, khususnya pada kelas sentimen negatif. Oleh karena itu, penerapan SMOTE membantu memperbaiki distribusi data sehingga model menjadi lebih seimbang dalam mengenali kedua kelas sentimen. Selain itu, dimensionality reduction menggunakan Truncated SVD berhasil mengurangi dimensi fitur TF-IDF tanpa menurunkan performa model secara signifikan.

Secara keseluruhan, kombinasi preprocessing teks, TF-IDF unigram-bigram, dan algoritma SVM menghasilkan performa klasifikasi yang cukup baik dalam mengidentifikasi sentimen pelanggan terhadap produk e-commerce. Hasil penelitian ini menunjukkan bahwa pendekatan text mining dan machine learning dapat dimanfaatkan untuk membantu memahami opini pelanggan secara otomatis berdasarkan data ulasan digital.

4.2. Saran

Penelitian ini masih memiliki beberapa keterbatasan yang dapat dikembangkan pada penelitian selanjutnya. Salah satu pengembangan yang dapat dilakukan adalah mencoba metode representasi fitur lain, seperti Word2Vec, FastText, atau transformer-based embedding agar model dapat memahami konteks kalimat secara lebih mendalam.

Selain itu, penelitian berikutnya dapat membandingkan performa SVM dengan algoritma lain, seperti Random Forest, XGBoost, Logistic Regression, maupun model deep learning berbasis LSTM atau BERT untuk mengetahui metode yang paling optimal pada klasifikasi sentimen ulasan e-commerce.

Penelitian selanjutnya juga disarankan menggunakan dataset yang lebih seimbang dan lebih beragam agar model memiliki kemampuan generalisasi yang lebih baik terhadap berbagai jenis ulasan pelanggan. Penggunaan teknik preprocessing tambahan, seperti lemmatization atau handling slang words, juga dapat dipertimbangkan untuk meningkatkan kualitas representasi teks.

Terakhir, hasil penelitian ini diharapkan dapat menjadi referensi bagi penelitian analisis sentimen selanjutnya, khususnya pada bidang e-commerce dan text mining berbasis machine learning.

5. DAFTAR PUSTAKA

- Harmandini, K. P., & Muslim, K. (2024). Analysis of TF-IDF and TF-RF Feature Extraction on Product Review Sentiment. *Sinkron: Jurnal dan Penelitian Teknik Informatika*. <https://jurnal.polgan.ac.id/index.php/sinkron/about>
- Ramadila, H., Syafitri, E. D., & Zamsuri, A. (2025). Sentiment Detection of Shopee E-Commerce Application Reviews Using Natural Language Processing and Support Vector Machine. *JAISEN: Journal of Advanced Information Systems and Engineering*. <https://journal.unilak.ac.id/index.php/jaisen/article/view/28481>
- Siregar, J. I. W., Siahaan, A. P. U., Iqbal, M., Nasution, D., & Wijaya, R. F. (2024). Sentiment Classification on E-Commerce User Reviews with Natural Language Processing (NLP) and Support Vector Machine (SVM) Methods. *International Journal of Computer Sciences and Mathematics Engineering*. <https://journal.fkpt.org/index.php/BIT/article/view/2018>
- Kosasih, R., & Alberto, A. (2021). Sentiment Analysis of Game Product on Shopee Using the TF-IDF Method and Naive Bayes Classifier. *ILKOM Jurnal Ilmiah*. <https://jurnal.fikom.umi.ac.id/index.php/ILKOM/article/view/721>
- Barus, H., Fajri, I., & Pristyanto, Y. (2024). *Sentiment Classification Analysis of Tokopedia Reviews Using TF-IDF, SMOTE, and Traditional Machine Learning Models*. *Journal of Applied Informatics and Computing*. <https://jurnal.polibatam.ac.id/index.php/JAIC>
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd Edition). O'Reilly Media. <https://books.google.co.id/books?id=V5ySEAAAQBAJ&printsec=copyright&hl=id#v=onepage&q&f=false>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. *Journal of Artificial Intelligence Research*. <https://www.jair.org/index.php/jair/article/view/10302>